



Evaluación Parcial N°2-ITY1101 Gestión de Datos para IA

Caso de Estudio 1: Sistema de Auditoría para una Fintech

Asignatura	Gestión De Datos Para IA 002D
Profesor	Hector Andres Morel Briones
Fecha	25 mayo 2026
Integrantes	Sebastian Cornejo, Jaime Alvarez y Lucas Fuentes

Resumen Ejecutivo del Proyecto: Sistema de Auditoría para una Fintech	3
Descripción de la Solución	3
Valor para la Organización	3
Justificación de la metodología de PMBOK aplicada	4
Planificación del proyecto	5
WBS con Carta Gantt	5
Descripción de la tecnología	5
Explicación técnica de cada etapa del pipeline	6
Ingesta (Capa Brozen)	6
Limpieza y transformación de los datos (Capa Silver)	7
Validación estructural y semántica de los datos	8
Carga de los datos	9
Plan de seguridad entorno Dataops (Leyes y cifrado)	10
Contención y Seguridad en Docker	10
Cifrado y Protección de Datos	10
Control de Acceso y Auditoría	10
Marco Normativo Financiero	11
Aplicación Práctica al Proyecto	11
Documentación del código con evidencias (logs, capturas) y link a repositorio GitHub (código, Dockerfile).	11
CSV con datos validos	11
CSV con datos invalidos	11
Status JSON:	12
Log	12
Repo GitHub	12
Estrategia de los principales KPI de monitoreo (indicador clave de desempeño)	13
Indicadores Globales y de Negocio	13
Indicadores de Trazabilidad y Linaje	13
Estabilidad y Monitoreo Operacional	14
Aplicación Práctica en la Demo y Defensa	14
Conclusiones de próximos pasos del proyecto	14
Próximos Pasos	14
Cierre	14

Resumen Ejecutivo del Proyecto: Sistema de Auditoría para una Fintech

Descripción de la Solución

Este proyecto se centra en establecer una base sólida y transparente para la gestión de transacciones de pago en una Fintech, priorizando la integridad y el cumplimiento normativo. La solución técnica es una **arquitectura Lakehouse**, la cual fue seleccionada por ser la única capaz de satisfacer los requisitos de **inmutabilidad** total de registros, transacciones **ACID** (Atomicidad, Consistencia, Aislamiento y Durabilidad) y soporte para auditorías exactas de datos históricos. El sistema implementa un pipeline de datos basado en la **Capa Medallion** (Bronze → Silver → Gold) y utiliza tecnología Delta Lake como motor de almacenamiento, lo que añade transacciones ACID y control de versiones ("time travel") para garantizar la inmutabilidad. La Capa Gold se expone mediante un Dashboard con Endpoint SQL para la entrega de reportes regulatorios fijos.

Valor para la Organización

La arquitectura propuesta ofrece un valor crítico al:

- **Garantizar el Cumplimiento Regulatorio:** Asegura que los registros jamás se alteren y elimina márgenes de error en la generación mensual de reportes regulatorios precisos y confiables.
- **Asegurar la Integridad de Datos:** La implementación de Delta Lake garantiza la inmutabilidad lógica y la trazabilidad de cada registro.
- **Proveer Auditoría Exacta:** Permite consultar el historial exacto de datos en cualquier momento a través de la funcionalidad de "time travel".
- **Ofrecer Escalabilidad y Eficiencia:** La separación del cómputo y el almacenamiento en el Lakehouse permite que el sistema absorba grandes volúmenes de transacciones sin degradar el rendimiento en la generación de reportes.
- **Validar la Seguridad:** El uso de una metodología predictiva (Cascada) asegura que cada fase de seguridad e inmutabilidad se valide rigurosamente antes de avanzar, garantizando la precisión técnica exigida por un sector regulado.

Justificación de la metodología de PMBOK aplicada

Basado en el caso del "Sistema de Auditoría para una Fintech", se optó por aplicar la metodología Predictiva (Cascada), la cual se alinea con el enfoque tradicional de gestión delineado por el **PMBOK**.

La justificación técnica y metodológica para elegir este enfoque tradicional frente a opciones ágiles o híbridas se fundamenta en los siguientes puntos:

- **Requisitos estáticos y definidos:** El proyecto posee reglas y requisitos absolutamente estrictos que están definidos desde el inicio y no cambiarán durante el ciclo de vida del desarrollo.
- **Entregables fijos sin necesidad de iteración:** El único producto final esperado son reportes regulatorios mensuales con una estructura fija. Esto elimina la necesidad de iterar constantemente sobre nuevas funcionalidades o de adaptar el sistema al *feedback* de los usuarios, algo que sí requeriría una metodología ágil.
- **Validación estricta de seguridad y precisión:** Al trabajar en un entorno regulado como una Fintech, el enfoque en cascada permite validar rigurosamente cada fase de seguridad e inmutabilidad de los datos antes de avanzar a la siguiente etapa. Esto asegura el orden, la calidad y el cumplimiento normativo exigido.
- **Prevención de sobrecarga de planificación:** Dado que el contexto es cerrado y no exploratorio, utilizar una metodología Ágil o Híbrida introduciría un *overhead* (sobrecarga) de planificación iterativa que resultaría completamente innecesario.

Planificación del proyecto

WBS con Carta Gantt

WBS aplicado a la metodología cascada con carta Gantt.

Fase (id)	Elemento	Tipo	Fecha Inicio	Fecha Término	Nivel
	Sistema de Auditoría Fintech	WBS	10-abr-2026		0
1	Gestión del Proyecto	WBS	10-abr-2026	13-abr-2026	1
1-1	Informe de encargo (Evaluación Parcial 1)	Entregable	10-abr-2026	13-abr-2026	2
1-1-1	README.md inicial del repositorio	Entregable	10-abr-2026	14-abr-2026	3
1-2	Hito 1: Plan de Trabajo Aprobado	Hito			2
2	Diseño de Arquitectura Lakehouse	WBS	22-may-2026	25-may-2026	1
2-1	Diseño de Capa Bronze (Ingesta Cruda e Inmutable)	Entregable	22-may-2026	22-may-2026	2
2-2	Diseño de Capa Silver (Limpieza y Estandarización)	Entregable	22-may-2026	22-may-2026	2
2-3	Diseño de Capa Gold (Curación y Reglas de Negocio)	Entregable	22-may-2026	22-may-2026	2
2-4	Documento de diseño técnico y Capas Medallion	Entregable	27-may-2026	27-may-2026	2
2-5	Hito 2: Arquitectura y Cumplimiento Aprobado	Hito			2
3	Ingeniería e Implementación de Datos	WBS	24-may-2026	24-may-2026	1
3-1	Configuración de entorno Delta Lake (ACID)	Entregable	24-may-2026	24-may-2026	2
3-2	Script de Ingesta y almacenamiento Bronze	Entregable	24-may-2026	24-may-2026	2
3-3	Script de transformación y validación Silver	Entregable	24-may-2026	24-may-2026	2
3-4	Carga de datos curados en Capa Gold para IA	Entregable	26-may-2026	27-may-2026	2
3-5	Hito 3: Capa Inmutable Operacional (Staging)	Hito			2
4	Servicio y Entrega de Reportes	WBS			1
4-1	README.md actualizado final	Entregable			2
4-2	Informe de Auditoría y Documento Consolidado	Entregable			2
4-3	Hito 4: Entrega final completa	Hito			2

Descripción de la tecnología

La tecnología utilizada para hacer seguimiento fue principalmente por el grupo de **WhatsApp** para la comunicación del grupo. También, usamos **Git Hub** como control de versiones para los procesos ETL para **Fintech**, por último **Docs** y **Sheet** de google para la documentación y **WBS** con carta Gantt para anotar el progreso individual.

Explicación técnica de cada etapa del pipeline

Ingesta (Capa Brozen)

La fase de ingesta es el punto de entrada de la tubería de datos. Se encarga de capturar la fuente cruda de transacciones financieras y persistir en la capa Bronze como una copia histórica e inmutable, garantizando la trazabilidad y la posibilidad de re-procesamiento completo de la información (*Conocida como replayability*).

- **Origen de datos:** Archivo CSV cargado de forma local en la ruta estandarizada **IA_Proyecto/data/raw/fintech_raw.csv**.
- **Script responsable:** **ingestion/lectura_csv.py** (con soporte modular en **IA_Proyecto/src/audit_utils.py**).
- **Operaciones clave:**
 - Lectura sencilla y liviana mediante **pandas.read_csv()**, configurada para procesamiento por bloques en caso de ficheros de gran volumen para optimizar el uso de memoria RAM.
 - Cálculo imperativo de un hash de registro criptográfico (**record_hash**) basado en el algoritmo SHA256 por cada fila. Esto asegura la inmutabilidad de la fuente y provee una llave única para el control de la idempotencia.
 - Inyección de metadatos de auditoría operacional en el registro: estampa de tiempo de ingesta (**ingested_at**), nombre del archivo origen, tamaño y contador de registros.
- **Gestión de errores y tolerancia a fallos:** Las filas que presenten malformaciones estructurales a nivel de parseo inicial son aisladas y derivadas de manera automática a registros de logs o archivos de rechazo específicos (*rejects*), evitando la interrupción del pipeline principal. No se aplican transformaciones semánticas en esta etapa para preservar la pureza del dato original.

Limpieza y transformación de los datos (Capa Silver)

Esta etapa procesa la transición de los datos desde la capa Bronze hacia la capa Silver. Su propósito es la sanitización técnica de las estructuras, la unificación de tipos nativos y la generación de variables derivadas críticas para las reglas del negocio financiero.

- **Script responsable:** `procesamiento/transformacion.py`.
- **Operaciones clave:**
 - **Normalización de tipos primitivos:** Conversión explícita de cadenas de texto a objetos temporales (`datetime`) homogeneizados en zona horaria UTC, y casteo seguro de valores monetarios a tipos flotantes (`float`) o decimales de alta precisión.
 - **Tratamiento de signos y flujos de caja:** Derivación automatizada de la columna `amount_signed`. El sistema aplica lógica matemática vectorial para asignar signo negativo a los montos cuyas operaciones correspondan a débitos o comisiones (**DEBIT** o **FEE**), permitiendo cálculos financieros directos downstream.
 - **Imputación y autoreparación de saldos:** Implementación de reglas de negocio para la resolución de nulos. Si el monto operacional está ausente pero se dispone de los saldos anterior y posterior, el pipeline deduce matemáticamente el valor exacto y repara el registro de forma nativa.
 - **Enriquecimiento dimensional:** Extracción y particionamiento de campos temporales (`created_date`, `created_month`) y normalización de cadenas de texto (remoción de espacios y caracteres especiales) en los campos de canales y notas operativas.
- **Salida:** Archivos estructurados en `IA_Proyecto/data/processed/fintech_limpio_*.csv` junto con sus metadatos de control operacional.

Validación estructural y semántica de los datos

Esta fase actúa como el motor de calidad de datos (*Data Quality*) y control de integridad del pipeline. Aplica un doble filtro restrictivo (estructural y de negocio) para asegurar que solo la información óptima avance hacia las capas analíticas o de persistencia relacional.

- **Módulo responsable:** `data_quality/validacion.py`.
- **Validación estructural (Schema Validation):**
 - Inspección obligatoria del contrato de datos: comprobación de presencia de llaves primarias y columnas esenciales (`transaction_id`, `account_id`, `amount`, `status`).
 - Evaluación de umbrales tolerables de valores nulos y formatos regex para identificadores. Los registros que fallan este esquema mínimo son rechazados inmediatamente.
- **Validación semántica (Reglas de Negocio Financieras):**
 - **Coherencia de estados operativos:** Auditoría estricta del campo `status`. Se verifica de forma dirigida que las transacciones con estado `FAILED` (fallidas) presenten consistencia interna, asegurando que el saldo inicial (`balance_before`) sea idéntico al saldo final (`balance_after`).
 - **Auditoría criptográfica de cadena:** Validación de la continuidad de los bloques cronológicos utilizando operaciones vectoriales desfasadas (`.shift()`). El script comprueba que el campo `prev_record_hash` del registro actual coincida exactamente con el `record_hash` de la transacción inmediatamente anterior por cuenta.
- **Salidas y trazabilidad:** Segmentación del flujo en dos universos: `fintech_limpio_*.csv` para registros aprobados y `fintech_invalidos_*.csv` para la cuarentena. Cada fila rechazada es enriquecida con columnas de diagnóstico (`valid`, `observaciones`) que especifican el motivo exacto de la falla para auditorías posteriores.

Carga de los datos

La etapa final del ciclo de vida del dato tiene como objetivo la persistencia física y la exposición segura de los datos limpios y los indicadores clave de rendimiento (KPIs) calculados.

- **Componentes responsables:** `carga/carga_datos.py` (almacenamiento en archivos y KPIs) y `carga/carga_postgres.py` (persistencia relacional).
- **Comportamiento y tolerancia a fallos (Fail-safe architecture):**
 - La inserción masiva en el motor relacional de PostgreSQL (mediante SQLAlchemy y el conector `psycopg2`) se encuentra completamente aislada dentro de bloques de control de excepciones `try/except` en el script director (`pipeline.py`).
 - **Mecanismo de contingencia activa:** Si el contenedor de Docker está apagado, el puerto de red está bloqueado o el servicio de la base de datos no responde, el pipeline captura el error, evita la caída del sistema en vivo y activa un plan de respaldo automático que desvía y escribe toda la data procesada y los KPIs en archivos físicos CSV locales (`salidas_emergencia/`) junto con un reporte de estado en formato JSON (`pipeline_status_*.json`).
- **Idempotencia y seguridad:**
 - Se utilizan estrategias de carga limpia mediante técnicas de truncado/append controlado para garantizar que ejecuciones repetidas de la demo no dupliquen la información en las tablas de destino.
 - Las credenciales de acceso a la base de datos se manejan de forma externa y segura a través de archivos de configuración de entorno (`.env`), resguardando los parámetros críticos fuera del repositorio de código.
 - Se dispone del script DDL estructurado `Script Postgrest.sql` en la raíz como plano de referencia para el despliegue del esquema y las tablas de *staging*.

Plan de seguridad entorno Dataops (Leyes y cifrado)

Contención y Seguridad en Docker

La infraestructura aplica aislamiento y privilegios mínimos para reducir la superficie de ataque y asegurar un entorno homogéneo.

- Aislamiento del Entorno: El `Dockerfile` fija la versión de Python y dependencias (`requirements.txt`), reduciendo discrepancias operativas entre máquinas.
- Menor Privilegio: El contenedor se ejecuta con restricciones en el host y sin credenciales embebidas en la imagen.
- Inyección de Secretos: Las credenciales de acceso se inyectan en ejecución mediante variables de entorno o archivos `.env` excluidos del repositorio.
- Gobernanza de Almacenamiento: La imagen no almacena datos productivos. El uso de volúmenes se limita a persistencia local controlada o pruebas.
- Redes Intermedias: Servicios como PostgREST operan en una red privada interna con autenticación, sin publicar puertos innecesarios.

Cifrado y Protección de Datos

Asegura la confidencialidad e integridad de la información transaccional en tránsito y en reposo.

- Cifrado en Tránsito: Las conexiones hacia PostgreSQL y servicios externos exigen de forma mandatoria protocolos seguros TLS/SSL.
- Cifrado en Reposo: Los archivos del pipeline y volúmenes de la base de datos se ubican sobre almacenamiento cifrado en producción.
- Hashing de Trazabilidad: Las columnas `record_hash` y `prev_record_hash` permiten detectar alteraciones estructurales en la cadena de transacciones.
- Mascaramiento Mínimo: Los sistemas de logs tienen prohibido exponer credenciales, tokens o identificadores financieros completos.

Control de Acceso y Auditoría

La gobernanza del pipeline garantiza el linaje del dato, limitando las acciones según el rol del componente.

- Permisos por Rol: Se segregan los accesos: lectura para análisis, escritura exclusiva para el proceso ETL y administración para despliegue.

- Telemetría de Ejecución: Cada ciclo se registra en logs y en un archivo de estado indexado para auditar éxitos o fallos de conexión.
- Linaje de Datos: Se conserva la metadata de ingestión e historial versionado para reconstruir el origen de cada salida analítica.

Marco Normativo Financiero

En el contexto Fintech, el tratamiento de datos se alinea con los principios de minimización, finalidad y trazabilidad. En Chile, el flujo cumple las exigencias de la Ley 19.628 sobre protección de la vida privada, adoptando la segregación de funciones y la retención limitada de datos

Aplicación Práctica al Proyecto

- Reproducibilidad: El pipeline corre en un contenedor aislado para garantizar el control de variables.
- Restricciones Estructurales: PostgreSQL se inicializa mediante [Script Postgres.sql](#), definiendo tablas, staging y restricciones lógicas ([CHECK](#), [REFERENCES](#)).
- Arquitectura Fail-Safe: La carga a la base de datos es desacoplada. Si PostgreSQL falla, el sistema captura la excepción y conserva los CSV, KPIs y logs en el almacenamiento local para asegurar la demo y la continuidad de la auditoría.

Documentación del código con evidencias (logs, capturas) y link a repositorio GitHub (código, Dockerfile).

CSV con datos validos

```
IA_Proyecto > data > processed > fintech_limpio_2026-05-27T100258309961Z.csv > data
1 transaction_id,created_at,reporting_month,account_id,counterparty_account,transaction_group_id,transaction_type,status,amount,currency,balance_before
2 tx000000-0000-0000-0000-000000000001,2026-01-01 08:00:00+00:00,2026-01,ACC1001,CLIENT-100,GRP-202601-01,CREDIT,COMPLETED,1000.0,USD,5000.0,6000.0,RPT01,
3 tx000000-0000-0000-0000-000000000002,2026-01-02 09:15:00+00:00,2026-01,ACC1001,VEN-9001,GRP-202601-01,DEBIT,COMPLETED,250.0,USD,6000.0,5750.0,RPT01,
4 tx000000-0000-0000-0000-000000000003,2026-01-03 10:05:00+00:00,2026-01,ACC1001,CLIENT-451,GRP-202601-02,CREDIT,COMPLETED,500.0,USD,5750.0,6250.0,RPT01,
5 tx000000-0000-0000-0000-000000000004,2026-01-04 11:00:00+00:00,2026-01,ACC1001,GRP-202601-03,FEE,COMPLETED,5.0,USD,6250.0,6245.0,RPT02,True,hash0
6 tx000000-0000-0000-0000-000000000006,2026-01-06 13:45:00+00:00,2026-01,ACC1002,MERCH-202,GRP-202601-11,DEBIT,COMPLETED,85.5,USD,4200.0,4114.5,RPT01,
7 tx000000-0000-0000-0000-000000000008,2026-01-08 15:30:00+00:00,2026-01,ACC1003,CLIENT-333,GRP-202601-21,CREDIT,COMPLETED,150.0,USD,1955.0,2105.0,RPT01,
8 tx000000-0000-0000-0000-00000000000A,2026-01-10 09:00:00+00:00,2026-01,ACC1005,CLIENT-555,GRP-202601-31,CREDIT,COMPLETED,300.0,USD,1500.0,1800.0,RPT01,
9 tx000000-0000-0000-0000-00000000000B,2026-01-11 10:10:00+00:00,2026-01,ACC1005,MERCH-303,GRP-202601-32,DEBIT,COMPLETED,60.0,USD,1800.0,1740.0,RPT01,
10 tx000000-0000-0000-0000-00000000000D,2026-01-13 12:35:00+00:00,2026-01,ACC1006,GRP-202601-41,DEBIT,COMPLETED,30.0,USD,650.0,620.0,RPT01,True,hash0
11 tx000000-0000-0000-0000-00000000000F,2026-01-15 14:55:00+00:00,2026-01,ACC1007,MERCH-404,GRP-202601-51,DEBIT,COMPLETED,75.25,USD,1100.0,1024.75,RPT01,
12 tx000000-0000-0000-0000-000000000011,2026-01-17 16:10:00+00:00,2026-01,ACC1008,MERCH-500,GRP-202601-61,DEBIT,COMPLETED,20.0,USD,530.0,510.0,RPT01,Tr
13 tx000000-0000-0000-0000-000000000013,2026-01-19 18:30:00+00:00,2026-01,ACC1009,MERCH-601,GRP-202601-71,DEBIT,COMPLETED,40.0,USD,750.0,710.0,RPT01,Tr
14 tx000000-0000-0000-0000-000000000015,2026-01-21 20:50:00+00:00,2026-01,ACC1010,MERCH-800,GRP-202601-81,DEBIT,COMPLETED,15.75,USD,1520.0,1504.25,RPT01,
15 tx000000-0000-0000-0000-000000000017,2026-01-23 09:10:00+00:00,2026-01,ACC1011,MERCH-909,GRP-202601-91,DEBIT,COMPLETED,60.0,USD,1000.0,940.0,RPT01,T
16 tx000000-0000-0000-0000-000000000019,2026-01-25 11:30:00+00:00,2026-01,ACC1012,MERCH-101,GRP-202601-93,DEBIT,COMPLETED,120.0,USD,650.0,530.0,RPT01,T
17 tx000000-0000-0000-0000-00000000001B,2026-01-27 13:50:00+00:00,2026-01,ACC1013,MERCH-202,GRP-202601-95,DEBIT,COMPLETED,30.0,USD,600.0,570.0,RPT01,Tr
18 tx000000-0000-0000-0000-00000000001D,2026-01-29 15:05:00+00:00,2026-01,ACC1014,MERCH-303,GRP-202601-97,DEBIT,COMPLETED,55.0,USD,1020.0,965.0,RPT01,T
19 tx000000-0000-0000-0000-00000000001F,2026-01-31 17:25:00+00:00,2026-01,ACC1015,MERCH-404,GRP-202601-99,DEBIT,COMPLETED,80.0,USD,900.0,820.0,RPT01,Tr
20 tx000000-0000-0000-0000-000000000036,2026-02-23 18:35:00+00:00,2026-02,ACC1020,MERCH-111,GRP-202602-23,DEBIT,COMPLETED,9.99,USD,100.0,90.01,RPT01,Tr
21
```

CSV con datos invalidos

```

transaction_id,created_at,reporting_month,account_id,counterparty_account,transaction_group_id,transaction_type,status,amount,currency,balance_before
tx000000-0000-0000-0000-000000000005,2026-01-05 12:30:00+00:00,2026-01,ACC1002,CLIENT-771,GRP-202601-10,CREDIT,COMPLETED,1200.0,USD,3000.0,4200.0,RPT0
tx000000-0000-0000-0000-000000000007,2026-01-07 14:20:00+00:00,2026-01,ACC1003,CLIENT-222,GRP-202601-20,DEBIT,COMPLETED,45.0,USD,2000.0,1955.0,RPT0
tx000000-0000-0000-0000-000000000009,2026-01-09 16:40:00+00:00,2026-01,ACC1004,MERCH-777,GRP-202601-30,DEBIT,COMPLETED,99.99,USD,999.0,700.01,RPT0
tx000000-0000-0000-0000-00000000000C,2026-01-12 11:25:00+00:00,2026-01,ACC1006,CLIENT-888,GRP-202601-40,CREDIT,COMPLETED,450.0,USD,200.0,650.0,RPT0
tx000000-0000-0000-0000-00000000000E,2026-01-14 13:45:00+00:00,2026-01,ACC1007,CLIENT-999,GRP-202601-50,CREDIT,COMPLETED,200.0,USD,900.0,1100.0,RPT0
tx000000-0000-0000-0000-000000000010,2026-01-16 15:05:00+00:00,2026-01,ACC1008,CLIENT-222,GRP-202601-60,CREDIT,COMPLETED,130.0,USD,400.0,530.0,RPT0
tx000000-0000-0000-0000-000000000012,2026-01-18 17:20:00+00:00,2026-01,ACC1009,CLIENT-444,GRP-202601-70,CREDIT,COMPLETED,700.0,USD,50.0,750.0,RPT0
tx000000-0000-0000-0000-000000000014,2026-01-20 10:40:00+00:00,2026-01,ACC1010,CLIENT-777,GRP-202601-80,CREDIT,COMPLETED,320.0,USD,1200.0,1520.0,RPT0
tx000000-0000-0000-0000-000000000016,2026-01-22 08:00:00+00:00,2026-01,ACC1011,CLIENT-121,GRP-202601-90,CREDIT,COMPLETED,900.0,USD,100.0,1000.0,RPT0
tx000000-0000-0000-0000-000000000018,2026-01-24 10:20:00+00:00,2026-01,ACC1012,CLIENT-212,GRP-202601-92,CREDIT,COMPLETED,250.0,USD,400.0,650.0,RPT0
tx000000-0000-0000-0000-00000000001A,2026-01-26 12:40:00+00:00,2026-01,ACC1013,CLIENT-313,GRP-202601-94,CREDIT,COMPLETED,400.0,USD,200.0,600.0,RPT0
tx000000-0000-0000-0000-00000000001C,2026-01-28 14:15:00+00:00,2026-01,ACC1014,CLIENT-414,GRP-202601-96,CREDIT,COMPLETED,220.0,USD,800.0,1020.0,RPT0
tx000000-0000-0000-0000-00000000001E,2026-01-30 16:15:00+00:00,2026-01,ACC1015,CLIENT-515,GRP-202601-98,CREDIT,COMPLETED,600.0,USD,300.0,900.0,RPT0
tx000000-0000-0000-0000-000000000020,2026-02-01 08:00:00+00:00,2026-02,ACC1001,CLIENT-100,GRP-202602-01,CREDIT,COMPLETED,2000.0,USD,5750.0,7750.0,RPT0
tx000000-0000-0000-0000-000000000021,2026-02-02 09:10:00+00:00,2026-02,ACC1002,CLIENT-771,GRP-202602-02,DEBIT,COMPLETED,150.0,USD,4200.0,4050.0,RPT0
tx000000-0000-0000-0000-000000000022,2026-02-03 10:20:00+00:00,2026-02,ACC1003,CLIENT-222,GRP-202602-03,CREDIT,COMPLETED,100.0,USD,1055.0,2055.0,RPT0
tx000000-0000-0000-0000-000000000023,2026-02-04 11:30:00+00:00,2026-02,ACC1004,MERCH-777,GRP-202602-04,DEBIT,COMPLETED,20.0,USD,700.01,680.01,RPT0
tx000000-0000-0000-0000-000000000024,2026-02-05 12:40:00+00:00,2026-02,ACC1005,CLIENT-555,GRP-202602-05,CREDIT,COMPLETED,250.0,USD,1800.0,2050.0,RPT0
tx000000-0000-0000-0000-000000000025,2026-02-06 13:50:00+00:00,2026-02,ACC1006,CLIENT-888,GRP-202602-06,DEBIT,COMPLETED,12.0,USD,650.0,638.0,RPT0
tx000000-0000-0000-0000-000000000026,2026-02-07 14:55:00+00:00,2026-02,ACC1007,CLIENT-999,GRP-202602-07,CREDIT,COMPLETED,400.0,USD,1100.0,1500.0,RPT0
tx000000-0000-0000-0000-000000000027,2026-02-08 15:05:00+00:00,2026-02,ACC1008,MERCH-500,GRP-202602-08,DEBIT,COMPLETED,15.0,USD,530.0,515.0,RPT0
tx000000-0000-0000-0000-000000000028,2026-02-09 16:15:00+00:00,2026-02,ACC1009,CLIENT-444,GRP-202602-09,CREDIT,COMPLETED,800.0,USD,750.0,1550.0,RPT0
tx000000-0000-0000-0000-000000000029,2026-02-10 17:25:00+00:00,2026-02,ACC1010,MERCH-303,GRP-202602-10,DEBIT,COMPLETED,60.0,USD,1520.0,1460.0,RPT0
tx000000-0000-0000-0000-00000000002A,2026-02-11 18:35:00+00:00,2026-02,ACC1011,CLIENT-121,GRP-202602-11,CREDIT,COMPLETED,950.0,USD,1000.0,1950.0,RPT0

```

KPI

```

IA_Proyecto > data > kpi > kpi_fintech_2026-05-27T100258360687Z.csv > data
1  kpi,valor,descripcion
2  total_registros,160.0,Registros totales procesados
3  registros_validos,19.0,Registros que pasaron validación
4  registros_invalidos,141.0,Registros descartados por validación
5  tasa_registros_validos,0.1187,Proporción de registros válidos
6  monto_total_valido,2886.49,Monto total de transacciones válidas
7  monto_promedio_valido,151.92,Monto promedio de transacciones válidas
8  saldo_promedio_final,2225.71,Saldo promedio posterior a la transacción
9  transacciones_confirmadas,19.0,Cantidad de transacciones con status COMPLETED
10 cuentas_unicas,15.0,Cantidad de cuentas distintas
11 meses_unicos,2.0,Cantidad de meses de reporte distintos
12

```

Status JSON:

```

IA_Proyecto > data > kpi > {} pipeline_status_2026-05-27T100258373902Z.json > ...
1  {
2    "etl_status": "success",
3    "postgres_status": "failed",
4    "postgres_error": "ValueError: Faltan variables de conexión en db.env: DB_HOST, DB_PORT, DB_NAME, DB_USER, DB_PASSWORD",
5    "timestamp": "2026-05-27T10:02:58.373980Z"
6  }

```


Log

```

2026-05-27 05:49:05.353 INFO pipeline: Pipeline iniciado. Log activo en IA_Proyecto\logs\pipeline_etl.log
2026-05-27 05:49:05.363 INFO ingestion.leer_csv: 1 registros sin 'record_hash', generando.
2026-05-27 05:49:05.368 INFO ingestion.leer_csv: Metadata guardada en IA_Proyecto\data\metadata\ingest_fintech_raw.csv_2026-05-27T094905360971Z.json
2026-05-27 05:49:05.369 INFO ingestion.leer_csv: Total líneas importadas: 160 from IA_Proyecto\data\raw\fintech_raw.csv
2026-05-27 05:49:05.470 ERROR pipeline: Falta la conexión a Postgres

```

Repo GitHub



Estrategia de los principales KPI de monitoreo (indicador clave de desempeño)

La estrategia de KPIs se orienta a medir de forma analítica la calidad de los datos, el linaje de la trazabilidad y la estabilidad operativa de la tubería de datos. Los indicadores clave se calculan de manera automatizada inmediatamente después de la fase de validación y se guardan como artefactos versionados en la ruta `IA_Proyecto/data/kpi/`. Esta arquitectura de persistencia faculta al sistema para auditar cada ciclo de ejecución de forma aislada y compararlo con ejecuciones históricas.

Indicadores Globales y de Negocio

Estos KPIs proveen una visión macro sobre la salud del lote de datos procesado y la consistencia financiera de las transacciones aprobadas.

- **total_registros:** Mide el volumen absoluto de filas ingeridas desde el archivo crudo original en la capa Bronze.
- **registros_validos y registros_invalidos:** Cuantifican el resultado directo de la aplicación del motor de reglas, segmentando la data apta de aquella enviada a la zona de cuarentena.
- **tasa_registros_validos:** Indicador porcentual de eficiencia que establece la proporción de registros que cumplen con el contrato de datos para consumo analítico downstream.
- **monto_total_valido y monto_promedio_valido:** Métricas agregadas de negocio que permiten realizar conciliaciones rápidas y comprobar la consistencia de los montos financieros validados.
- **saldo_promedio_final:** Indicador de control contable diseñado para detectar desvíos numéricos o anomalías extremas en los balances posteriores a las transacciones.
- **transacciones_confirmadas:** Métrica operativa que contabiliza exclusivamente los movimientos consolidados con estado exitoso (**COMPLETED**).

Indicadores de Trazabilidad y Linaje

Garantizan el control sobre el alcance, la distribución de la información y la inmutabilidad de la auditoría.

- **cuentas_unicas:** Mide la cobertura y dispersión de los identificadores de cuenta (**account_id**) incluidos en la ejecución actual.
- **meses_unicos:** Evalúa la distribución y el alcance temporal del lote analizado según su mes de reporte.
- **Auditoría de Hashes criptográficos:** Aunque los campos **record_hash** y **prev_record_hash** no se consolidan como métricas numéricas agregadas, actúan como el sustento técnico que viabiliza la detección de alteraciones y la gobernanza sobre el linaje del dato.

Estabilidad y Monitoreo Operacional

Esta capa vincula el comportamiento de las reglas de negocio con la telemetría técnica de la infraestructura.

- **Preservación y Reproducibilidad:** Los archivos de KPIs se versionan de forma síncrona junto con las salidas limpias (capa Silver), asegurando la reproducibilidad estricta de las auditorías.
- **Desacoplamiento Técnico:** El archivo de metadatos `pipeline_status_*.json` complementa la lectura de los KPIs de negocio al registrar el estado del backend, indicando de forma determinista si la persistencia hacia PostgreSQL se ejecutó con éxito o reportó fallos de conectividad.
- **Monitoreo Híbrido:** Dado que la persistencia en la base de datos se ejecuta en un bloque aislado que no bloquea la continuidad del flujo, el monitoreo del sistema unifica con éxito los resultados financieros con el estado de los servicios containerizados en Docker.

Aplicación Práctica en la Demo y Defensa

En el escenario de la defensa del proyecto, esta matriz de KPIs constituye la herramienta principal de visualización para demostrar la solidez del desarrollo en tiempo real:

- **Validación en un Clic:** Permite exponer de forma inmediata la efectividad del flujo ETL, reflejando cuántos registros pasaron los controles y el porcentaje exacto que fue retenido por inconsistencias.
- **Garantía de Carga:** Ofrece visibilidad clara sobre si las salidas del pipeline quedaron estructuradas correctamente para su explotación analítica o si se activaron los protocolos de contingencia local ante la ausencia de la base de datos relacional.

Conclusiones de próximos pasos del proyecto

El proyecto consolida una arquitectura funcional, reproducible y resiliente para la auditoría de transacciones financieras. Con un ETL robusto y K

Próximos Pasos

- **Modelado Gráfico:** Completar el diagrama de la arquitectura de datos (capas Bronze, Silver y Gold) y actualizar el diagrama de Gantt.
- **Pruebas Relacionales:** Configurar el archivo `.env` local para validar la inserción masiva e idempotencia (`ON CONFLICT / Truncate`) en PostgreSQL.
- **Refinamiento de KPIs:** Expandir el motor métrico con cálculos vectorizados por tipo de transacción (`CREDIT/DEBIT`) y detección analítica de anomalías.
- **Gobernanza de Evidencias:** Estructurar logs, metadatos de linaje y archivos CSV en el repositorio como sustento técnico ante la comisión.
- **Estrategia de Demo:** Utilizar `pipeline.py` para la orquestación automatizada y el notebook `pipeline_fintech.ipynb` como la capa de presentación interactiva.

Cierre

El proyecto cumple los objetivos de ingeniería fundamentales: procesa flujos transaccionales con trazabilidad criptográfica, aísla registros inconsistentes mediante reglas estrictas, consolida indicadores clave y documenta el proceso en un formato técnico, auditable y defendible.